Sinyal ve Gürültü: Hava Kalitesi İstatistiksel Analizi

AirQualityUCI Sensör Verilerinde Dağılım Modellemesi, Anomali Tespiti ve Hipotez Testleri

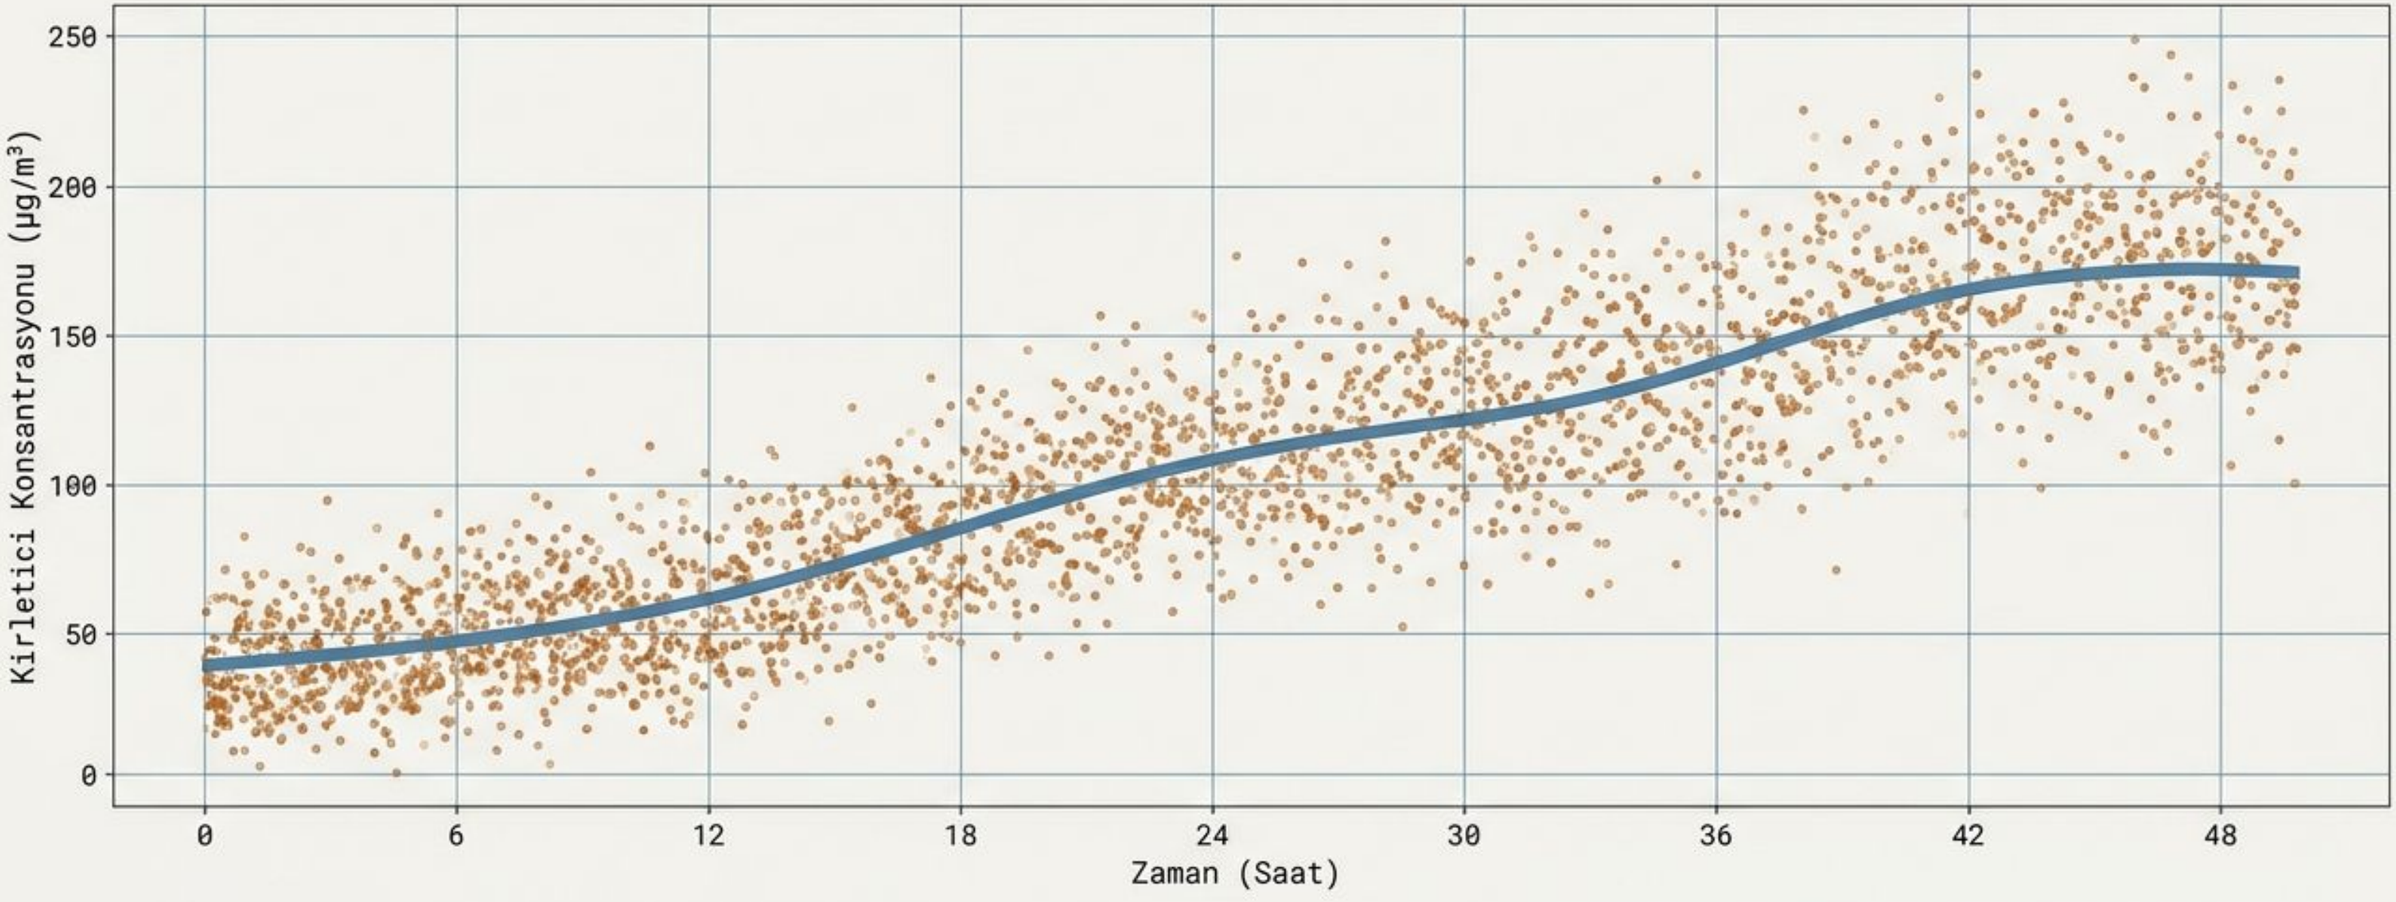

İstatistik ve Veri Bilimi Proje Raporu

Proje Amacı

Ham sensör verisindeki istatistiksel eğilimleri (sinyal) ortaya çıkarmak ve matematiksel modellerle aykırı değerleri (gürültü) izole etmek.

Veri Seti

AirQualityUCI (Çok değişkenli hava kalitesi izleme verisi). 9357 saatlik ölçüm, 15 öznitelik (`CO`, `NOx`, `Sıcaklık`, `Bağıl Nem`).

Analitik Hedef

Normal dağılım parametre tahmini, Shapiro-Wilk normallik testi ve Z-skoru tabanlı anomali filtresi uygulamak.

Kalite Standartları

Temiz kod prensipleri, modüler Python mimarisi ve tam tekrarlanabilirlik (`Reproducibility: seed=42`).

Strateji Karşılaştırması: Eksik Veri (-200) İle Nasıl Başa Çıkılır?

Senaryo 1: Satır Silme (Dropna)	Senaryo 2: Ortalama ile Doldurma (Imputation)
Veri Boyutu: 6,941 Satır (%25 Veri Kaybı)	**Veri Boyutu:** 9,357 Satır (Kayıp Yok)
Varyans Etkisi: Dağılımın doğal şekli korunur.	**Varyans Etkisi:** Ortalamaya yığılma olur. Varyans daralır.
Risk: Eğer eksik veriler rastgele değilse, modelde önyargı (bias) yaratabilir.	**Risk:** Merkezde yapay bir tepe noktası (artificial peak) oluşturarak normallik testlerini manipüle eder ve zayıflatır.

9,357 Satır

Ham Sensör Verisi

Hata Tespiti: Sensör arızalarını temsil eden **-200** değerleri **NaN** (boşluk) değerine dönüştürüldü.

6,941 Satır

Analize Hazır Temiz Veri (12 Kolon)

Veri setinin **~%25**'i sensör hataları ve eksik ölçümler nedeniyle yapısal olarak filtrelendi.

Çöp Veri Giren, Çöp Çıkar (GIGO) prensibi gereği kirlilik izole edildi.

Sayısal Keşif

2.18

Ortalama CO (GT)

1.17.75 °C

Ortalama Sıcaklık (T)

10.55

Ortalama Benzen (C6H6)

Dağılım Aralıkları (Min-Max)

Sıcaklık (T)

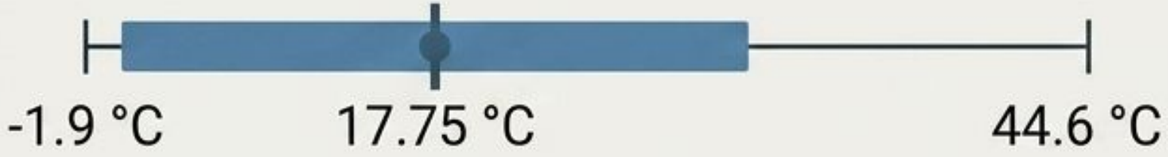

Bağıl Nem (RH)

İçgörü: Veri setindeki geniş aralıklar (örneğin Sıcaklık: -1.9°C ile 44.6°C arası), mevsimsel varyasyonları ve potansiyel anomalileri işaret etmektedir.

İleri Analiz: Dağılımlar ve İlişkiler

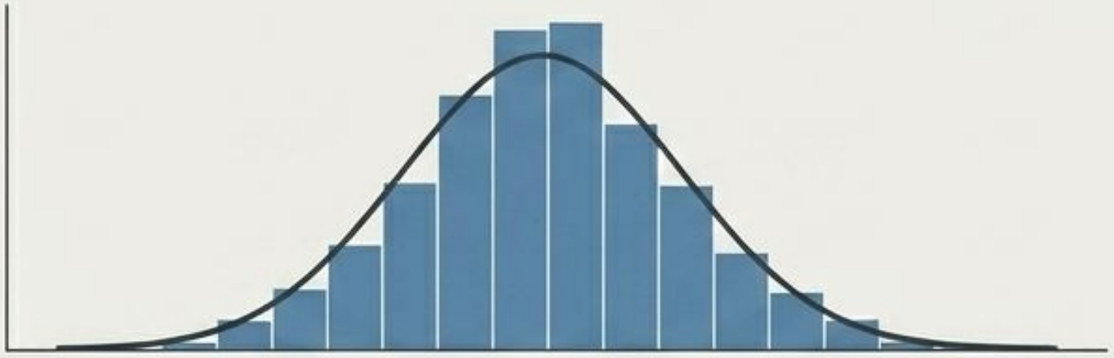

Sıcaklık dağılımı çan eğrisini andırıyor, ancak tepe noktası teorik idealden farklı.

Negatif korelasyon eğilimi: Sıcaklık arttıkça bağıl nem düşüyor.

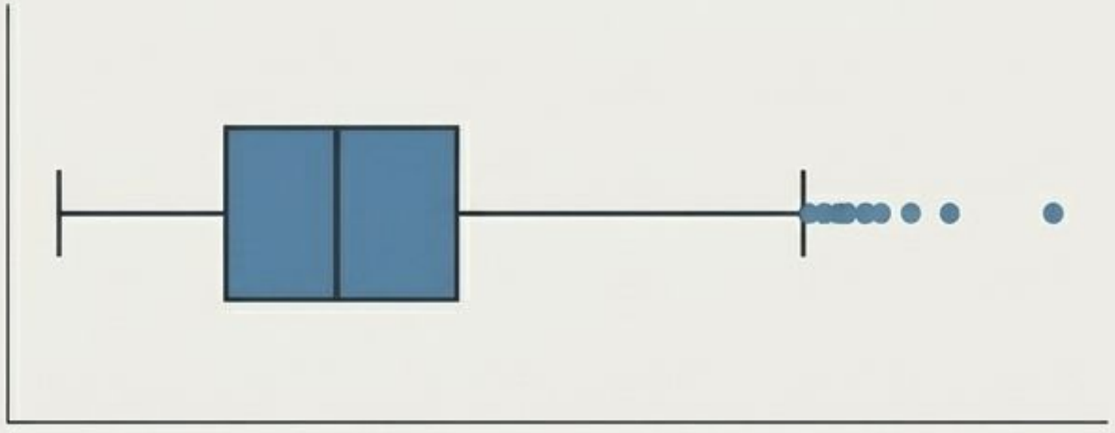

CO Kutu Grafiği: Sağ kuyrukta belirgin aykırı değerler (outliers) kümeleniyor.

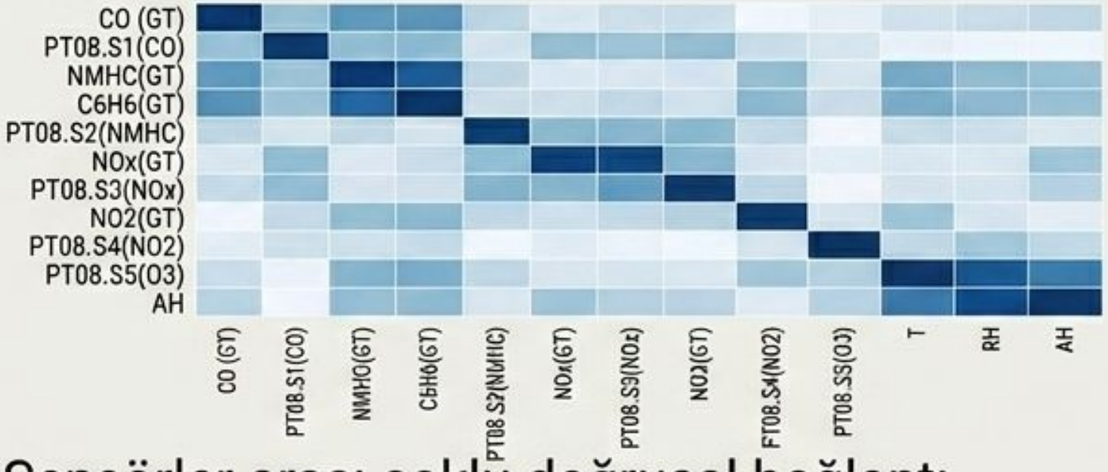

Sensörler arası çoklu doğrusal bağlantı mevcut (**Özellikle CO ve Benzen** arasında).

$$Z = \frac{X - \mu}{\sigma}$$

X: Bireysel Gözlem Değeri

μ: Popülasyon Ortalaması (Merkezi Eğilim)

σ: Standart Sapma (Yayılım/Varyans)

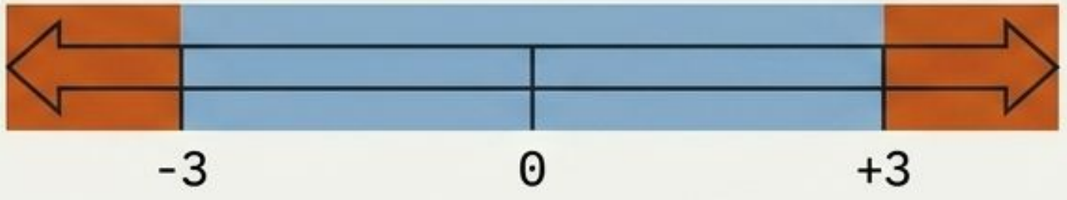

|Z| > 3 Kuralı: Veri noktası ortalamadan 3 standart sapma uzaktaysa, %99.7'lik normal alanın dışındadır. Bu istatistiksel bir anomali olarak kabul edilir.

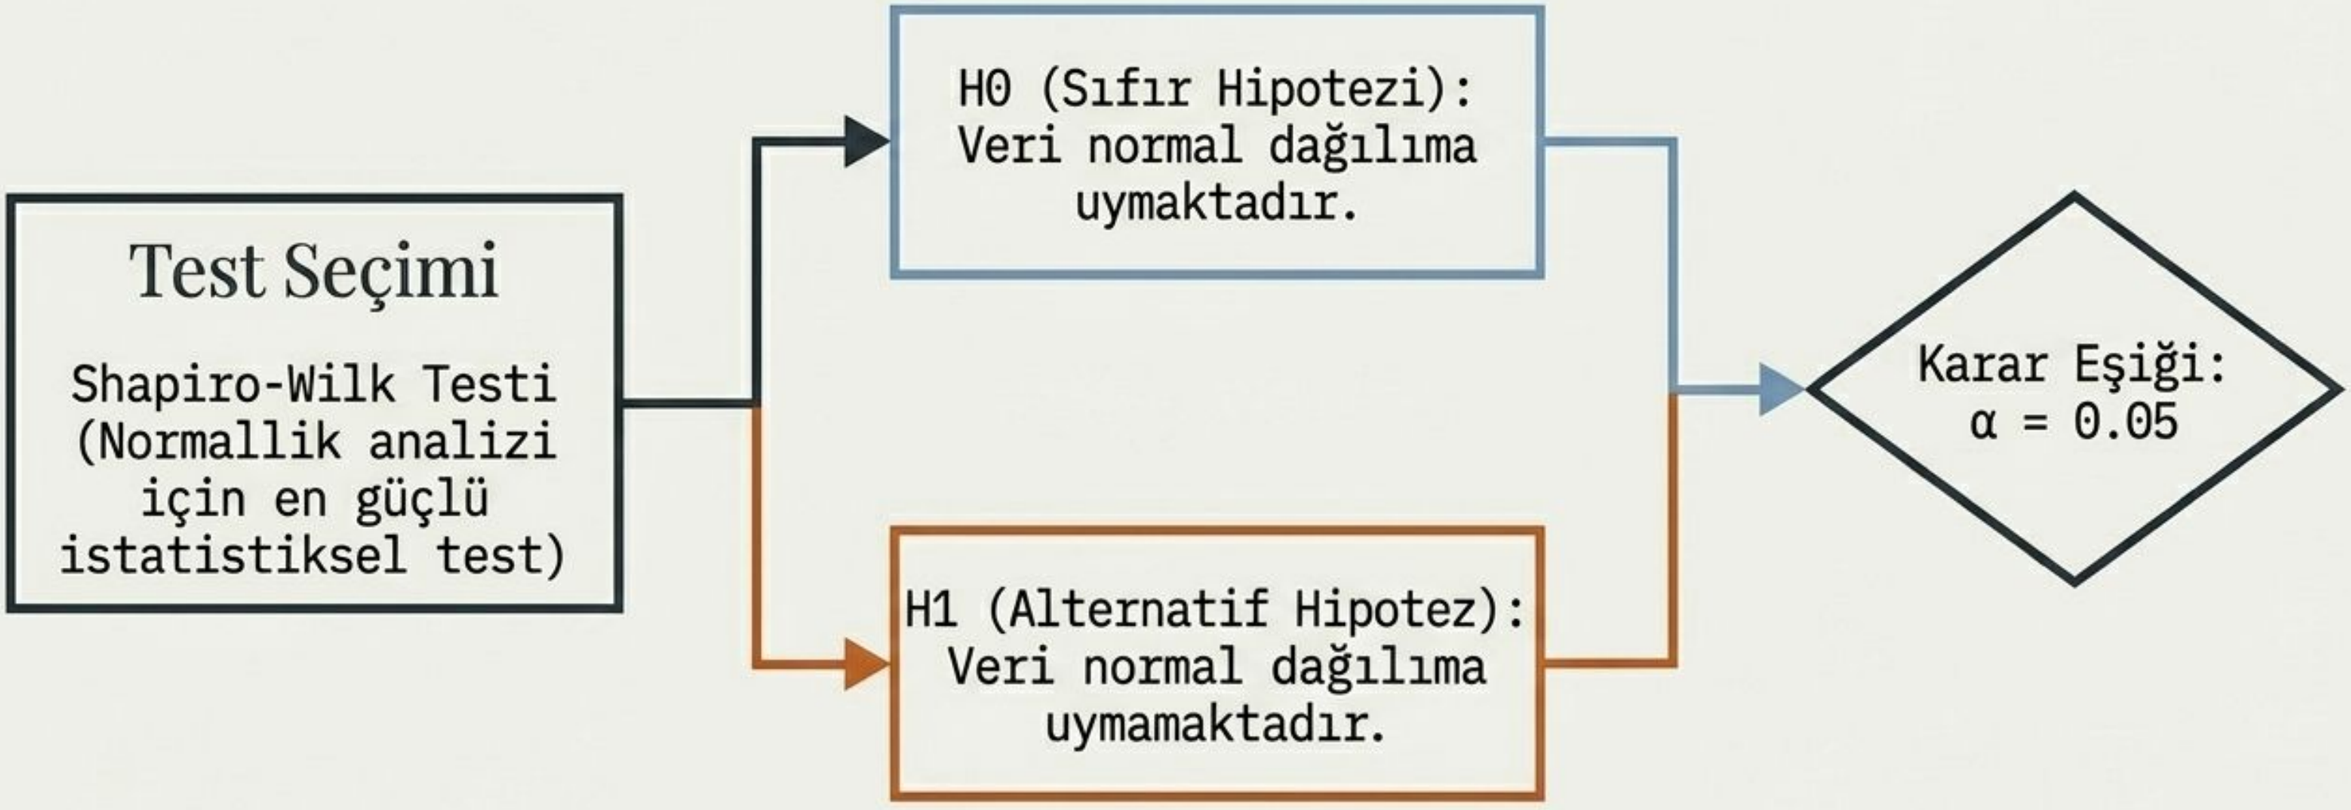

Metodolojik Kısıt:
N > 5000 (Bizim verimiz 6941) durumunda SciPy Shapiro testi aşrı hassaslaşır ve önemsiz sapmaları bile anlamlı bulabilir. Bu nedenle Q-Q Plot ile görsel doğrulama zorunludur.

Sıcaklık (T) Dağılım Modeli: Parametre Tahmini

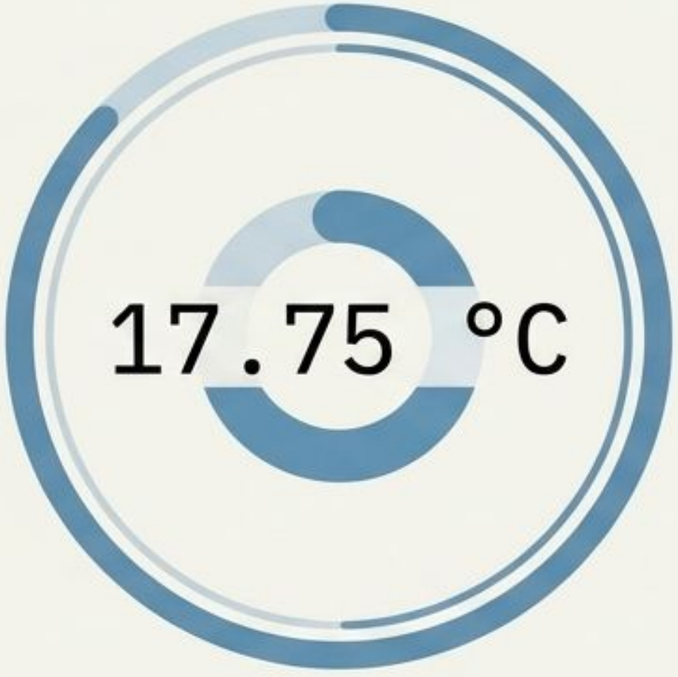

μ (Ortalama)
Verinin Merkezi Eğilimi

σ (Standart Sapma)
Verinin Yayılımı

Eğer bu veri kusursuz bir normal dağılım olsaydı, teorik modelimiz $X \sim N(17.75, 8.84^2)$ şeklinde ifade edilecekti. Peki gerçek veri bu teoriye ne kadar uyuyor?

Bell Curve (Normal Distribution

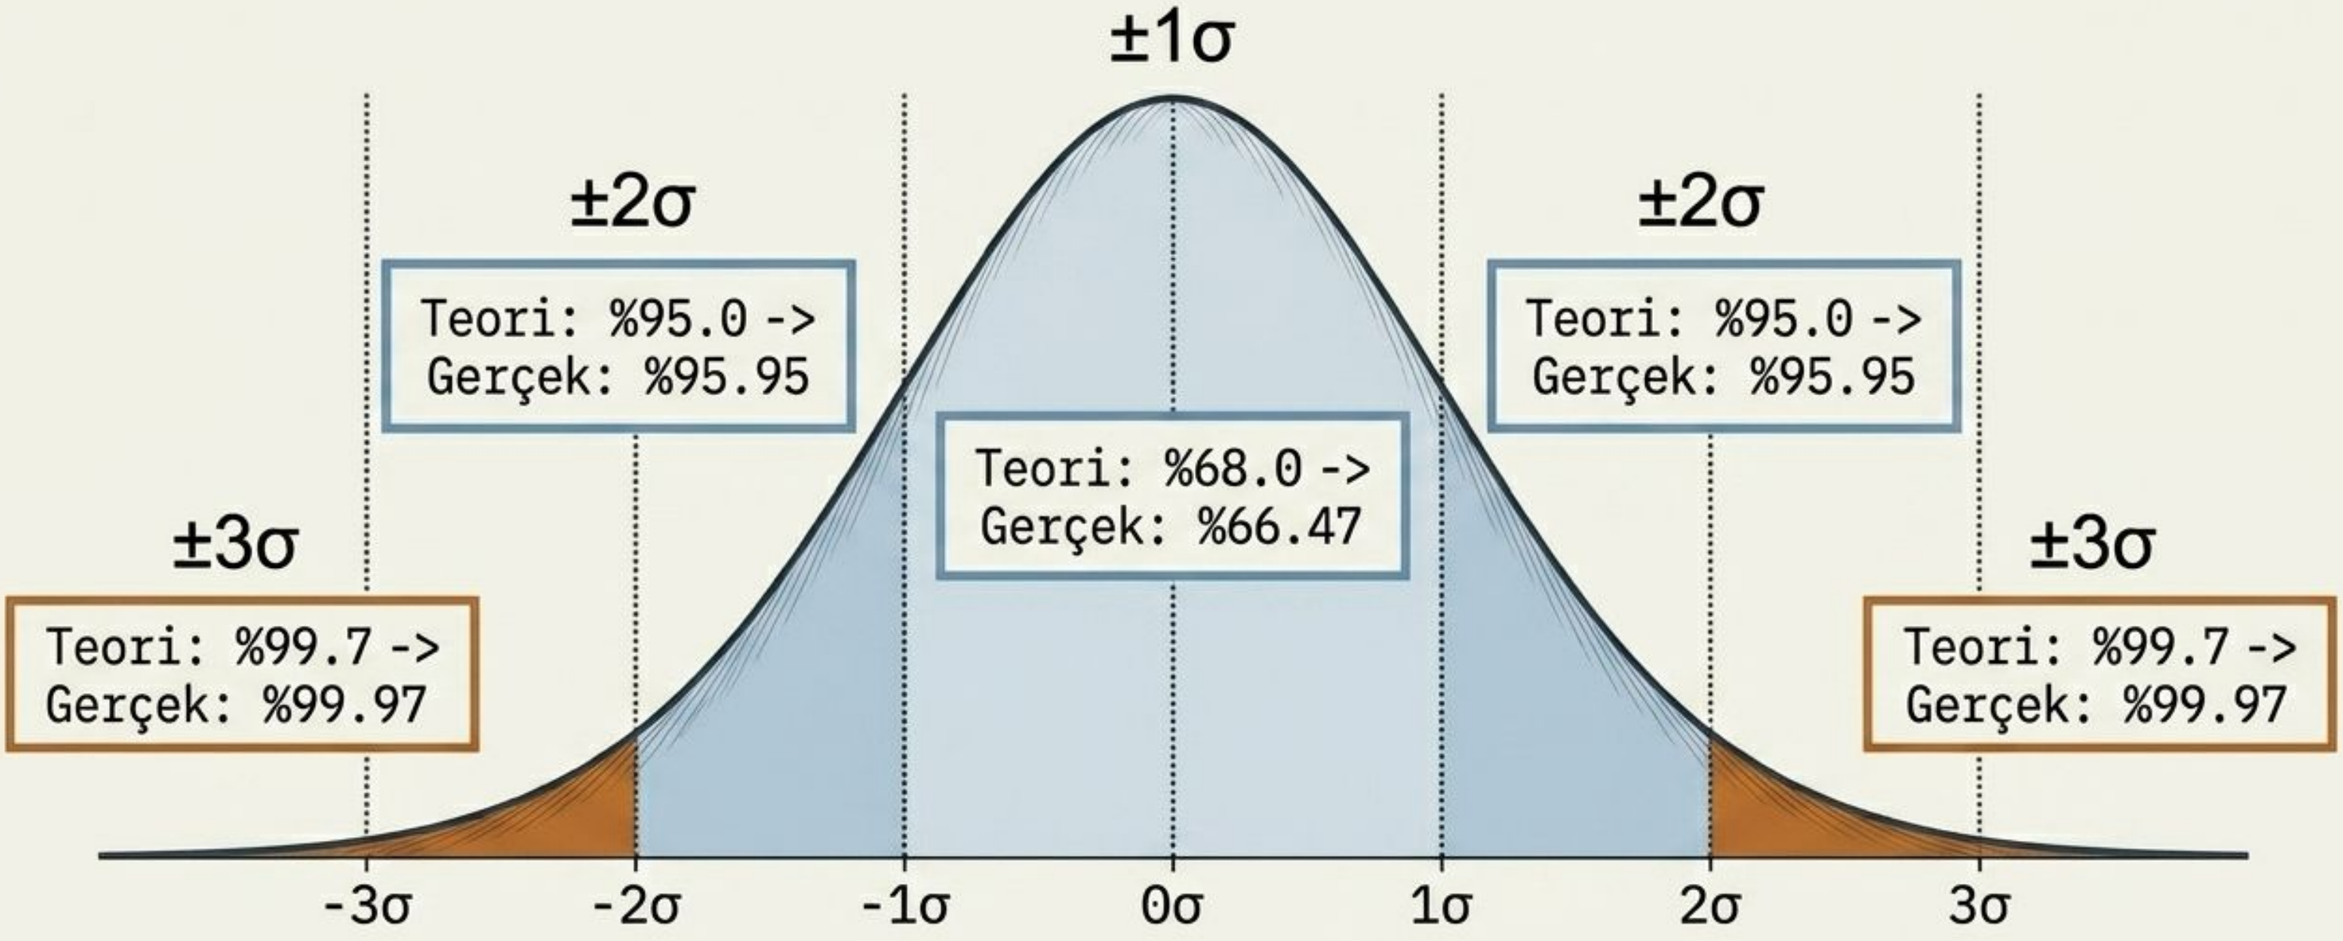

Sonuç: Gerçek veri ampirik kurallara büyük ölçüde yaklaşsa da, merkezde ve aşırı uçlarda teorik idealden sapmaktadır.

Görsel Kanıt: Q-Q Plot

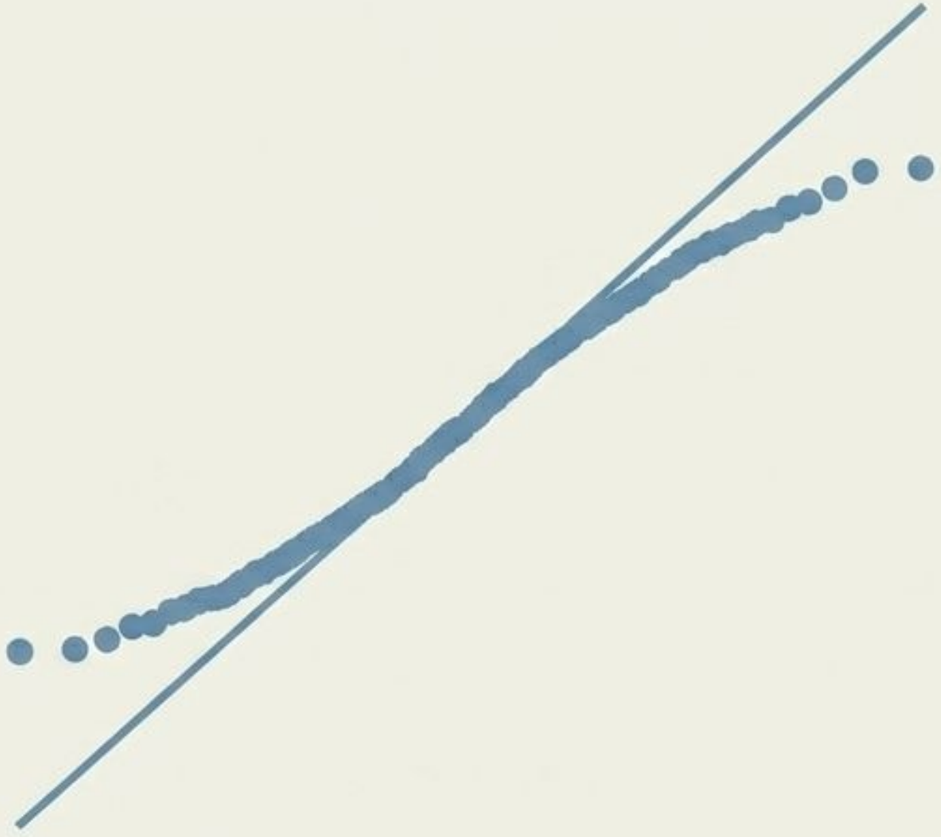

Kuyruklardaki (tails) sapmalar normalliğin bozulduğunu gösteriyor.

İstatistiksel Kanıt: Shapiro-Wilk

$$W = 0.9816$$

$$p\text{-value} = 4.87 \times 10^{-29}$$

H0 REDDEDİLDİ

$p < 0.05$ olduğu için Sıfır Hipotezi kesin olarak reddedilir. Veri katı bir istatistiksel normal dağılıma uymamaktadır.

Popülasyon Ortalaması için %95 Güven Aralığı

[17.54, 17.96]

Hava kalitesi sensörünün ölçeceği gerçek sıcaklık ortalaması
%95 olasılıkla bu dar bandın içindedir.

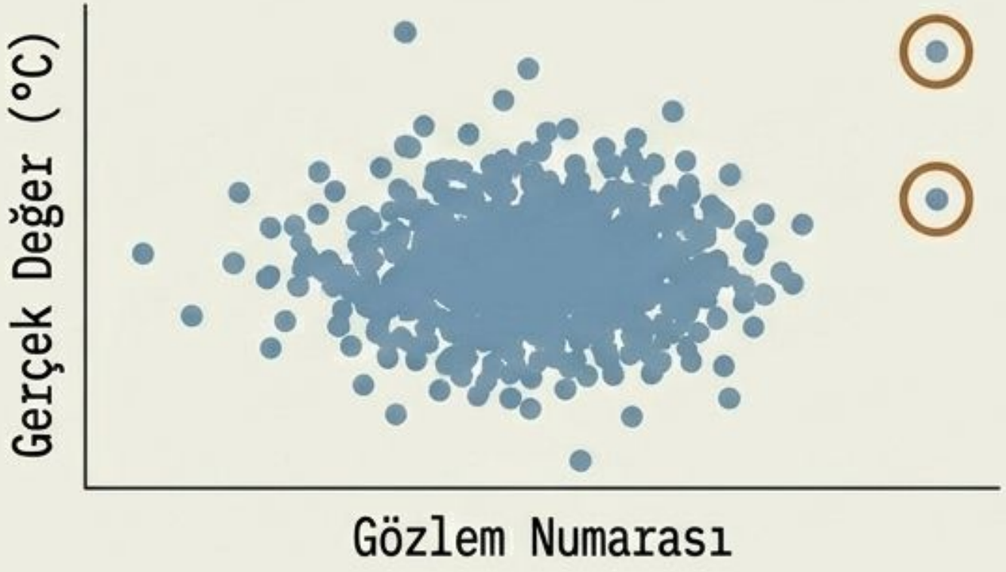

Z > 3 Sınırını Aşan Tespitler:

Gözlem #3213 -> Gerçek Değer: 44.3 °C (Z-Skoru: 3.001)
Gözlem #3214 -> Gerçek Değer: 44.6 °C (Z-Skoru: 3.035)

Soru: Bu uç değerler sensör kalibrasyon hatası mı, yoksa nadir görülen bir iklim ekstremitesi mi?

Temiz Kod ve Ölçeklenebilirlik (Mühendislik Yaklaşımı)

```
import python
import python
import np.conto as np
import rooms = a1
import =
class Mode(a:
    def __anil_rap(sif):
        ir = new[]:
            ""istatistiksel name, is""
```

```
np.random.seed(42)
```

```
    def root_in_get():
        for noti in song:
            print("(mens_veri + np_sets))
            self.vandom = [.]
            self.lannals:rdringlexs)
```

Tekrarlanabilirlik

Bilimsel sonuçların her çalıştırıldığında aynı kalmasını sağlayan deterministik yapı.

```
import python
import python
import np.conto as np
import rooms = a1
import =
class Mode(3:
    def __anil_rap(sif):
        ir = new[]:
            ""istatistiksel name, is""
```

```
def istatistiksel_analiz_yap():
```

```
    def root_in_get():
        for neti in song:
            print("(mens_veri + np_sets))
            self.vandox = [.]
            self.lannals:rdringlexs)
```

Modüler Mimari

Spagetti kod yerine, herhangi bir kolon veya veri seti için yeniden kullanılabilen kapsüllenmiş fonksiyonlar.

```
import python
import python
import np.conto as np
import roems = a1
import
class Mode(3:
    def __anil_rap(sif):
        ir = newf]:
            ""istatistiksel name, is""
```

```
def istatistiksel_analiz_yap():
```

```
    def reot_in_get():
        for noti in song:
            print("(mens_veri + np_sets))
            self.vandox = [.]
            self.lannals:rdringlexs)
```

Temiz Kod (PEP-8)

Anlamlı değişken isimlendirmeleri, kapsamlı *docstring* dokümantasyonları ve bağımsız main orkestrasyonu.

Varsayımlar ve İstatistiksel Sınırlamalar

Büyük N Hassasiyeti

6,941 satırlık veri, p-değerini sıfıra çok hızlı iter. Doğadan gelen gerçek veriler hiçbir zaman kusursuz bir matematiksel denkleme tam uymaz; bu nedenle büyük veri setlerinde H0 neredeyse her zaman reddedilir.

Korelasyon ≠ Nedensellik

CO ve Benzen arasında yüksek pozitif korelasyon saptanmıştır, ancak bu istatistiksel bir bağıntıdır. Kimyasal veya çevresel bir neden-sonuç ilişkisi kurmak için alan uzmanlığı gerekir.

Zaman Serisi Etkisi

Sensör verileri zamana bağlıdır. İstatistiksel testlerdeki 'veri noktalarının birbirinden bağımsız olduğu' (I.I.D.) varsayımı, bu tür zamansal verilerde mükemmel çalışmayabilir.

Özet Bulgular

- Sıcaklık dağılımı çan eğrisine büyük ölçüde yaklaşmış (±2σ için %95.95), ancak istatistiksel normallik testi geçilememiştir ($p < 0.05$).
- Z-Skoru ve Güven Aralıkları kullanılarak, popülasyon dinamiğinden sapan gerçek aykırı değerler (> 44°C) başarıyla izole edilmiştir.

Öneriler ve Gelecek Çalışmalar

Basit istatistiksel modellerin (Z-Skoru) yetersiz kalabileceği çok boyutlu anomaliler için Makine Öğrenmesi (Isolation Forest, SVM) entegrasyonu test edilmelidir.

Kaynaklar

Veri: AirQuality UCI Machine Learning Repository

Altyapı: Python (SciPy, Pandas, Matplotlib, Seaborn)

Referans: İstatistiksel Dağılımlar ve Hipotez Testleri Proje Yönergeleri